

# 线性方程组的数值解法

直接法

- 低阶稠密矩阵

迭代法

- 大型稀疏矩阵

极小化法

- 优化、非线性及病态问题

## 第六节 极小化方法

- 一、线性方程组的等价问题
- 二、最速下降法
- 三、共轭斜量法(共轭梯度法)
- 四、预条件共轭斜量法

# 一、与线性方程组等价的变分问题

设 $A$ 对称正定，求解的线性方程组为

$$Ax = b \quad (1)$$

其中 $A = (a_{ij}) \in R^{n \times n}$ ,  $x = (x_1, x_2, \dots, x_n)^T$ ,  $b = (b_1, b_2, \dots, b_n)^T$

对应的二次函数 $\varphi: R^{n \times n} \rightarrow R$ ，称为模函数，定义为

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i \quad (2)$$

**例：** 设  $A = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}$ ,  $b = \begin{bmatrix} 4 \\ 10 \end{bmatrix}$

$$\varphi(x) = \frac{1}{2}(x_1^2 + 6x_2^2 + 4x_1x_2) - (4x_1 + 10x_2)$$

$\varphi$ 有如下性质:

$$\varphi(x) = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j - \sum_{i=1}^n b_i x_i$$

(1) 对一切  $x \in R^n$ , 有  $\nabla \varphi(x) = \text{grad} \varphi(x) = Ax - b = -r$

证: 
$$\frac{\partial \varphi}{\partial x_i} = \sum_{j=1}^n a_{ij} x_j - b_i = -r_i, \quad i = 1, 2, \dots, n$$

$$\text{grad} \varphi(x) = \begin{bmatrix} \frac{\partial \varphi}{\partial x_1} & \dots & \frac{\partial \varphi}{\partial x_n} \end{bmatrix}^T = Ax - b = -r$$

例: 设  $A = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}, \quad b = \begin{bmatrix} 4 \\ 10 \end{bmatrix}$

$$\varphi(x) = \frac{1}{2} (x_1^2 + 6x_2^2 + 4x_1x_2) - (4x_1 + 10x_2)$$

$$\frac{\partial \varphi}{\partial x_1} = x_1 + 2x_2 - 4 = -r_1, \quad \frac{\partial \varphi}{\partial x_2} = 2x_1 + 6x_2 - 10 = -r_2$$

(2) 对一切  $x, y \in R^n, \alpha \in R$

$$\varphi(x + \alpha y) = \frac{1}{2}(A(x + \alpha y), x + \alpha y) - (b, x + \alpha y)$$

$$= \frac{1}{2}(Ax, x) - (b, x) + \alpha(Ax, y) - \alpha(b, y) + \frac{\alpha^2}{2}(Ay, y)$$

$$= \varphi(x) + \alpha(Ax - b, y) + \frac{\alpha^2}{2}(Ay, y)$$

$$\varphi(x) = \frac{1}{2}(Ax, x) - (b, x)$$

(3) 设  $x^* = A^{-1}b$  为  $Ax = b$  的解, 则

$$\varphi(x^*) = \frac{1}{2}(Ax^*, x^*) - (b, x^*)$$

$$\varphi(x^*) = -\frac{1}{2}(b, A^{-1}b) = -\frac{1}{2}(Ax^*, x^*)$$

对一切  $x \in R^n$ , 有

$$\varphi(x) - \varphi(x^*) = \frac{1}{2}(Ax, x) - (b, x) + \frac{1}{2}(Ax^*, x^*)$$

$$= \frac{1}{2}(Ax, x) - (Ax^*, x) + \frac{1}{2}(Ax^*, x^*)$$

$$= \frac{1}{2}(A(x - x^*), x - x^*)$$

**定理：** 设 $A$ 对称正定，则 $x^*=A^{-1}b$ 为 $Ax=b$ 解的充分必要条件是： $x^*$ 是二次函数 $\varphi(x)$ 的极小值点，即

$$x^*=A^{-1}b \Leftrightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x)$$

证明：

$$\varphi(x) - \varphi(x^*) = \frac{1}{2} (A(x - x^*), x - x^*)$$

设 $x^*=A^{-1}b$ ，由上式及 $A$ 的正定性，

$$\varphi(x) - \varphi(x^*) \geq 0$$

所以有 $\varphi(x^*) \leq \varphi(x)$ ， $\forall x \in R^n$ ，即 $x^*$ 使 $\varphi(x)$ 达到最小。

**充分性：** 若 $x^*$ 使 $\varphi(x)$ 取极小值，则有

$$\text{grad} \varphi(x) \Big|_{x=x^*} = Ax^* - b = 0,$$

即 $x^*$ 是方程组 $Ax=b$ 的解。

$$\nabla \varphi(x) = \text{grad} \varphi(x) = Ax - b$$

求二次函数 $\varphi(x)$ 极小值点的一般方法是：  
构造一个向量序列 $\{x^{(k)}\}$ ，使 $\varphi(x^{(k)}) \rightarrow \min \varphi(x)$

可以采取以下方法：

(1)任取一个初始向量 $x^{(0)}$ ，

(2)构造迭代格式

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}, \quad (k = 0, 1, \dots)$$

其中 $\underline{p^{(k)}}$ 是搜索方向， $\underline{\alpha_k}$ 是搜索步长，



可以采取以下方法:

(1)任取一个初始向量 $x^{(0)}$ ,

(2)构造迭代格式

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}, \quad (k = 0, 1, \dots)$$

其中 $p^{(k)}$ 是搜索方向,  $\alpha_k$ 是搜索步长,

(3)选择 $p^{(k)}$ 和 $\alpha_k$ 使得

$$\varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha_k p^{(k)}) < \varphi(x^{(k)})$$

则当 $k \rightarrow \infty$ 时, 有 $\varphi(x^{(k)}) \rightarrow \varphi(x^*) = \min_{x \in R^n} \varphi(x)$

(4)给出误差限 $\varepsilon$ , 直到

$$\|x^{(k)} - x^{(k-1)}\| < \varepsilon \text{ 或 } \|r^{(k)}\| = \|b - Ax^{(k)}\| < \varepsilon$$

迭代终止。

## 对迭代格式

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}, \quad (k = 0, 1, \dots)$$

关键是要确定搜索方向 $\mathbf{p}^{(k)}$ 和搜索步长 $\alpha_k$ 。

### (1) 确定搜索方向 $\mathbf{p}^{(k)}$

**最速下降法：** $\mathbf{p}^{(k)}$ 取为模函数 $\varphi(x)$ 减少最快的方向，  
即： $\varphi(x)$ 的负梯度方向 $-\text{grad}(\varphi(x))$ 。

**共轭梯度法：**取A-共轭方向 $\mathbf{p}^{(k)}$ 。

### (2) 确定搜索步长 $\alpha_k$

确定 $\alpha_k$ 使得从k步到k+1步是最优的，即：

$$\varphi(\mathbf{x}^{(k+1)}) = \varphi(\mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)}) = \min_{\alpha} \varphi(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)})$$

这称为沿 $\mathbf{p}^{(k)}$ 方向的一维极小搜索。 $\varphi(\mathbf{x}^{(k+1)})$ 是局部极小。

对确定的搜索方向  $p^{(k)}$ , 构造一个  $\alpha$  的函数

$$\begin{aligned}
 F(\alpha) &= \varphi(x^{(k+1)}) = \varphi(x^{(k)} + \alpha p^{(k)}) \\
 &= \frac{1}{2} (A(x^{(k)} + \alpha p^{(k)}), x^{(k)} + \alpha p^{(k)}) - (b, x^{(k)} + \alpha p^{(k)}) \\
 &= \frac{1}{2} (Ax^{(k)}, x^{(k)}) - (b, x^{(k)}) + \alpha (Ax^{(k)}, p^{(k)}) - (\alpha, b^{(k)} p^{(k)}) \\
 &\quad + \frac{\alpha^2}{2} (Ap^{(k)}, p^{(k)}) \\
 &= \varphi(x^{(k)}) + \alpha (Ax^{(k)} - b, p^{(k)}) + \frac{\alpha^2}{2} (Ap^{(k)}, p^{(k)}) \\
 &= \varphi(x^{(k)}) - \alpha (r^{(k)}, p^{(k)}) + \frac{\alpha^2}{2} (Ap^{(k)}, p^{(k)}) \\
 &\text{令 } F'(\alpha) = 0, \text{ 即: } -(r^{(k)}, p^{(k)}) + (\alpha Ap^{(k)}, p^{(k)}) = 0
 \end{aligned}$$

$$F'(\alpha) = -(r^{(k)}, p^{(k)}) + \alpha(Ap^{(k)}, p^{(k)})$$

得 
$$\alpha = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$\because F''(\alpha) = (Ap^{(k)}, p^{(k)}) > 0, \quad (A \text{ 正定})$$

取 
$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}, \quad \alpha_k \text{ 是 } \varphi(x^{(k)} + \alpha p^{(k)}) \text{ 下降的极小值点,}$$


即  $\alpha_k$  是  $k \rightarrow k+1$  步的最优步长。

## 二、最速下降法

最速下降法：

$p^{(k)}$ 取模函数 $\varphi(x)$ 减少最快的方向，  
即： $\varphi(x)$ 的负梯度方向

$$\begin{aligned} p^{(k)} &= -\text{grad}(\varphi(x^{(k)})) \\ &= r^{(k)} \end{aligned}$$



**例：** 设  $A = \begin{bmatrix} 1 & 2 \\ 2 & 6 \end{bmatrix}$ ,  $b = \begin{bmatrix} 4 \\ 10 \end{bmatrix}$

$$\varphi(x) = \frac{1}{2}(x_1^2 + 6x_2^2 + 4x_1x_2) - (4x_1 + 10x_2)$$

$$\frac{\partial \varphi}{\partial x_1} = x_1 + 2x_2 - 4 = -r_1, \quad \frac{\partial \varphi}{\partial x_2} = 2x_1 + 6x_2 - 10 = -r_2$$

$$\varphi(x^*) = \min \varphi(x) = -9, \quad x^* = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

## 最速下降算法:

(1) 选取  $x^{(0)} \in R^n$

(2) 对  $k = 0, 1, 2, \dots$

$$r^{(k)} = b - Ax^{(k)}$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}$$


(3) 当  $\|x^{(k+1)} - x^{(k)}\| < \varepsilon$  时, 终止迭代。

$$p^{(k)} = -\text{grad}(\varphi(x^{(k)})) = r^{(k)}$$

$$\alpha = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

# 最速下降法的特点

- (1) 初始点可任选，每次迭代计算量小，存储量少，程序简短。即使从一个不好的初始点出发，开始的几步迭代，目标函数值下降很快，然后慢慢逼近局部极小点
- (2) 任意相邻两点的搜索方向是**正交**的，它的迭代路径为绕道逼近极小点。当迭代点接近极小点时，步长变得很小，越走越慢





### 三、共轭斜量法 (CG) (共轭梯度法)

设按方向  $p^{(0)}, p^{(1)}, \dots, p^{(k-1)}$  已进行  $k$  次一维搜索, 求得  $x^{(k)}$ , 下一步就是确定  $p^{(k)}$ , 再求解一维极小化问题

$$\min_{\alpha} \varphi(x^{(k)} + \alpha p^{(k)})$$

可得 
$$\alpha = \alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} \quad (7)$$

现在考虑  $p^{(0)}, p^{(1)}, \dots$  取什么方向

**定义:**  $A$  对称正定, 若  $R^n$  中向量组  $\{p^{(0)}, \dots, p^{(l)}\}$  满足

$$(Ap^{(i)}, p^{(j)}) = 0, \quad i \neq j$$

则称它为  $R^n$  中的一个  $A$ -共轭向量组。

## 计算 $p^{(k)}$ :

取  $p^{(0)} = r^{(0)}$ ,  $p^{(k)}$  就取为与  $p^{(0)}, \dots, p^{(k-1)}$   $A$ -共轭的向量, 这样的向量不是唯一的, CG法中取  $p^{(k)}$  为  $r^{(k)}$  与  $p^{(k-1)}$  的线性组合, 设

$$p^{(k)} = r^{(k)} + \beta_{k-1} p^{(k-1)} \quad (13)$$

可以证明这样得到的向量序列  $\{p^{(k)}\}$  是一个  $A$ -共轭向量组.

$$\text{经化简得到 } \beta_{k-1} = \frac{(r^{(k)}, r^{(k)})}{(r^{(k-1)}, r^{(k-1)})}$$

## 计算 $\alpha_k$ :

由  $A$ -共轭及  $p^{(k)}$  的定义得到

$$\alpha_k = \frac{(r^{(k)}, p^{(k)})}{(Ap^{(k)}, p^{(k)})} = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})} \quad (16)$$

## CG算法:

$$(1) x^{(0)} \in R^{(n)}$$

$$(2) r^{(0)} = b - Ax^{(0)}, p^{(0)} = r^{(0)}$$

$$(3) k = 0, 1, \dots,$$

$$\alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)},$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)},$$

$$\beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})}$$

$$p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)}$$

在计算过程中, 若遇  
 $r^{(k)}=0$ , 或  $(p^{(k)}, Ap^{(k)})=0$  时,  
计算终止,  $x^{(k)} = x^*$ .

- (1) 剩余向量相互正交，而 $R^n$ 中至多有 $n$ 个相互正交的非零向量，所以 $r^{(0)}, r^{(1)}, \dots, r^{(n)}$ 中至少有一个向量为零。若 $r^{(k)}=0$ ，则 $x^{(k)} = x^*$ 。
- (2) 实际计算中，由于舍入误差的影响， $n$ 步内得不到准确解，故还需继续迭代。一般因 $p^{(0)}, p^{(1)}, \dots, p^{(n-1)}$ 是一组 $A$ -共轭向量组，继续迭代时，要取 $x^{(n)} = x^{(0)}$ 。
- (3) 由误差估计式

$$\|x^{(k)} - x^*\|_A \leq 2 \left[ \frac{\sqrt{\text{cond}(A)_2} - 1}{\sqrt{\text{cond}(A)_2} + 1} \right]^k \|x^{(0)} - x^*\|_A$$

当 $A$ 的条件数很小时，共轭斜量法收敛很快，但当 $A$ 是病态严重的矩阵时，共轭斜量法收敛速度很慢。可采用预处理技术，降低 $A$ 的条件数。

## 四、预条件共轭斜量法(PCG)

寻找一个非奇异矩阵C, 使 $\bar{A}=C^{-1}AC^{-T}$ 的条件数比原系数矩阵A的条件数得到改善.

$$Ax = b \Leftrightarrow C^{-1}AC^{-T}C^Tx = C^{-1}b \Leftrightarrow \bar{A}\bar{x} = \bar{b}$$

$$\text{其中 } \bar{A} = C^{-1}AC^{-T}, \bar{b} = C^{-1}b, \bar{x} = C^Tx,$$

令 $M=CC^T$ 称为预优矩阵, 当M接近A时,  $\bar{A}$ 接近单位阵,  $\text{cond}(\bar{A})_2$ 接近1, 对 $\bar{A}\bar{x} = \bar{b}$ 用共轭斜量法求解, 可达到加速的目的。

$$M = CC^T \approx A,$$

$$\bar{A} = C^{-1}AC^{-T} \approx C^{-1}MC^{-T} = C^{-1}CC^TC^{-T} = I, \text{cond}(\bar{A})_2 \approx 1$$

## 预条件共轭斜量法

1、计算  $\bar{A} = C^{-1}AC^{-T}, \bar{b} = C^{-1}b$

2、解  $\bar{A}\bar{x} = \bar{b}$ , 得  $\bar{x}^{(k)}$ ,

$$(1) \bar{x}^{(0)} \in R^{(n)}$$

$$(2) \bar{r}^{(0)} = \bar{b} - \bar{A}\bar{x}^{(0)}, \bar{p}^{(0)} = \bar{r}^{(0)}$$

(3)  $k = 0, 1, \dots,$

$$\bar{\alpha}_k = \frac{(\bar{r}^{(k)}, \bar{r}^{(k)})}{(\bar{A}\bar{p}^{(k)}, \bar{p}^{(k)})}$$

$$\bar{x}^{(k+1)} = \bar{x}^{(k)} + \bar{\alpha}_k \bar{p}^{(k)},$$

$$\bar{r}^{(k+1)} = \bar{r}^{(k)} - \bar{\alpha}_k \bar{A}\bar{p}^{(k)},$$

$$\bar{\beta}_k = \frac{(\bar{r}^{(k+1)}, \bar{r}^{(k+1)})}{(\bar{r}^{(k)}, \bar{r}^{(k)})}$$

$$\bar{p}^{(k+1)} = \bar{r}^{(k+1)} + \bar{\beta}_k \bar{p}^{(k)}$$

$$3、\bar{x}^{(k)} = C^{-T} x^{(k)}.$$

实际计算，可通过  
变换，转化成用原方程  
组的量来计算

## PCG算法：

- (1)取初值 $x^{(0)} \in R^{(n)}, r^{(0)} = b - Ax^{(0)}$ ,
- (2)解方程组 $Mz^{(0)} = r^{(0)}$ , 求出 $z^{(0)}$ , 令 $p^{(0)} = z^{(0)}$
- (3) $k = 0, 1, \dots$ ,

$$\alpha_k = \frac{(z^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})}$$

$$x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)}$$

$$r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}$$

$$\text{解方程组 } Mz^{(k+1)} = r^{(k+1)}$$

$$\beta_k = \frac{(z^{(k+1)}, r^{(k+1)})}{(z^{(k)}, r^{(k)})}$$

$$p^{(k+1)} = z^{(k+1)} + \beta_k p^{(k)}$$

- (4)直到 $\|r^{(k+1)}\| < \varepsilon$ , 输出 $x^{(k+1)}$ 。

## 预优矩阵的选取

预优矩阵 $M = CC^T$ 应满足：

(1) $M$ 是对称正定的矩阵；(2) 方程组 $Mz^{(k)} = r^{(k)}$ 容易求解。

预条件共轭斜量法MATLAB的三种调用格式：

1.不用预优矩阵的共轭斜量法

$x = \text{pcg}(a, b, \text{tol}, k_{\max})$

2.用预优矩阵的共轭斜量法

(1)  $x = \text{pcg}(a, b, \text{tol}, k_{\max}, m)$

(2)  $r = \text{chol}(m)$

$x = \text{pcg}(a, b, \text{tol}, k_{\max}, r', r, x_0)$

3.未给定预优矩阵的共轭斜量法

$r = \text{cholinc}(sa, '0')$

$x = \text{pcg}(a, b, \text{tol}, k_{\max}, r', r, x_0)$