

复习:

连续函数最佳平方逼近问题的一般提法

在内积空间 $C[a,b]$ 中, 设 $f(x) \in C[a,b]$, 但 $f(x) \notin H \subset C[a,b]$,

在 H 中寻找一个元素 $s(x) = \sum_{j=0}^n c_j \varphi_j(x) \in H$

使得

$$\|f - s\|_2^2 = \min_{\varphi \in H} \|f - \varphi\|_2^2$$

若 $s(x)$ 存在, 则称其为 $f(x)$ 在 $[a,b]$ 上的最佳平方逼近函数。

第三节 离散数据的最小二乘拟合

一、最小二乘曲线拟合问题的一般提法

给定 $m+1$ 个数据点 $x_i = x_0, x_1, \dots, x_m$,
 $f(x_i) = f(x_0), f(x_1), \dots, f(x_m)$,

及权系数 $\omega_0, \omega_1, \dots, \omega_m$, 并已知函数模型 $s(x, c)$ 。

用给定的数据点, 按给定的函数模型, 构造拟合函数 $s(x)$ 逼近未知函数 $f(x)$, 使

$$\sum_{i=0}^m \omega_i (f(x_i) - s(x_i))^2 = \min \quad (1)$$

称为最小二乘曲线拟合(离散数据的最佳平方逼近)。

使拟合误差的平方和最小——最小二乘原理

两种拟合问题

1. 线性最小二乘曲线拟合

如：取 $s(x, c) = c_n x^n + c_{n-1} x^{n-1} + \cdots + c_1 x + c_0$

$s(x, c)$ 是关于系数 $c = (c_0, c_1, \cdots, c_{n-1}, c_n)^T$ 的线性函数。
这是多项式拟合。

若取 $s(x, c) = c_n e^{-x^n} + \cdots + c_2 e^{-x^2} + c_1 e^{-x} + c_0$,

这也是关于系数的线性拟合。

2. 非线性最小二乘曲线拟合

$s(x, c)$ 是关于系数 $c = (c_0, c_1, \cdots, c_{n-1}, c_n)^T$ 的非线性函数。

如： $s(x, c) = c_0 x + c_1 e^{-c_2 x}$

复习:

连续函数最佳平方逼近问题的一般提法

在内积空间 $C[a,b]$ 中, 设 $f(x) \in C[a,b]$, 但 $f(x) \notin H \subset C[a,b]$,

在 H 中寻找一个元素 $s(x) = \sum_{j=0}^n c_j \varphi_j(x) \in H$

使得

$$\|f - s\|_2^2 = \min_{\varphi \in H} \|f - \varphi\|_2^2$$

若 $s(x)$ 存在, 则称其为 $f(x)$ 在 $[a,b]$ 上的最佳平方逼近函数。

离散数据的最佳平方逼近问题的一般提法

在内积空间 $C[a,b]$ 中, 设 $f(x) \in C[a,b]$, 但 $f(x) \notin H \subset C[a,b]$,

在 H 中寻找一个元素 $s(x) = \sum_{j=0}^n c_j \varphi_j(x) \in H$

使得 $\|f - s\|_2^2 = \min$ 即 $\sum_{i=0}^m \omega_i (f(x_i) - s(x_i))^2 = \min$

若 $s(x)$ 存在, 则称其为 $f(x)$ 在 $[a,b]$ 上的最佳平方逼近函数 (最小二乘拟合曲线)。

连续函数内积空间

在 $C[a,b]$ 中, 定义带权 $\rho(x)$ 内积

$$(f, g) = \int_a^b \rho(x) f(x) g(x) dx$$

及内积范数 $\|f\|_2 = \sqrt{(f(x), f(x))} = \left(\int_a^b \rho(x) (f(x))^2 dx \right)^{\frac{1}{2}}$

离散内积空间

在 $C[a,b]$ 中, 定义带权 $\omega_i (i = 0, 1, \dots, m)$ 的内积

$$(f(x), \varphi(x)) = \sum_{i=0}^m \omega_i f(x_i) \varphi(x_i) = Y^T W \Phi = (Y, \Phi)$$

其中 $W = \text{diag}(\omega_0, \omega_1, \dots, \omega_m)$

$$Y = (f(x_0), f(x_1), \dots, f(x_m))^T$$

$$\Phi = (\varphi(x_0), \varphi(x_1), \dots, \varphi(x_m))^T$$

二、线性最小二乘曲线拟合问题的法方程

$$\text{求 } s(x) \in \Phi = \text{span} \{ \varphi_0(x), \varphi_1(x), \dots, \varphi_n(x) \}$$

其中 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ 线性无关。 $s(x) = \sum_{i=0}^n c_i \varphi_i(x)$

$$\text{由}(f-s, \varphi_k) = (f - \sum_{j=0}^n c_j \varphi_j, \varphi_k) = 0 (k = 0, 1, \dots, n)$$

得法方程

[illegible]

若记向量 $C = (c_0, c_1, \dots, c_n)^T \in R^{n+1}$

用矩阵形式表示为 $GC = F$, 称 $GC = F$ 为法方程

由函数 $\varphi_j(x)$ 和点集 $\{x_0, x_1, \dots, x_m\}$ 定义一个向量

$$\Phi_j = \begin{pmatrix} \varphi_j(x_0) \\ \varphi_j(x_1) \\ \vdots \\ \varphi_j(x_m) \end{pmatrix} \in R^{m+1}, j = 0, 1, \dots, n \quad Y = \begin{pmatrix} f(x_0) \\ f(x_1) \\ \vdots \\ f(x_m) \end{pmatrix}$$

连续函数拟合的法方程

[illegible]

离散数据拟合的法方程可改写为

[illegible]

[illegible]
$$GC = F$$

$$\text{其中 } G = \begin{bmatrix} (\Phi_0, \Phi_0) & (\Phi_1, \Phi_0) & (\Phi_n, \Phi_0) \\ (\Phi_0, \Phi_1) & (\Phi_1, \Phi_1) & (\Phi_n, \Phi_1) \\ (\Phi_0, \Phi_n) & (\Phi_1, \Phi_n) & (\Phi_n, \Phi_n) \end{bmatrix}$$

$$F = \left((Y, \Phi_0) \quad (Y, \Phi_1) \quad \cdots \quad (Y, \Phi_n) \right)^T$$

结论：若 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ 在点集 $\{x_i\}_{i=0}^m$ 上线性无关，且 $n < m$ ，因此 $\Phi_0, \Phi_1, \dots, \Phi_n$ 是 R^{m+1} 中线性无关的向量组。

例：取 $\varphi_0(x) = 1, \varphi_1(x) = x, \dots, \varphi_n(x) = x^n$,

x_0, x_1, \dots, x_n 为 $n+1$ 个互异点

$$\Phi_j = \begin{pmatrix} \varphi_j(x_0) \\ \varphi_j(x_1) \\ \vdots \\ \varphi_j(x_n) \end{pmatrix} = \begin{pmatrix} x_0^j \\ x_1^j \\ \vdots \\ x_n^j \end{pmatrix} \in R^{n+1}, j = 0, 1, \dots, n$$

设 $A = [\Phi_0, \Phi_1, \dots, \Phi_n]$

$$\det(A) = \begin{vmatrix} 1 & x_0 & \cdots & x_0^n \\ 1 & x_1 & \cdots & x_1^n \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_n & \cdots & x_n^n \end{vmatrix} = \prod_{0 \leq j < i \leq n} (x_i - x_j) \neq 0$$

所以 $\Phi_0, \Phi_1, \dots, \Phi_n$ 是 R^{n+1} 中线性无关的向量组。

法方程的另一种形式

记 $A = (\Phi_0, \Phi_1, \dots, \Phi_n)$,

由矩阵乘法可知 $G = A^T W A$, $F = A^T W Y$

法方程就变成 $A^T W A C = A^T W Y$

当 $W = I$ 时, 法方程为 $A^T A C = A^T Y$

$$\begin{aligned}
 A^T A &= \begin{bmatrix} \Phi_0^T \\ \Phi_1^T \\ \vdots \\ \Phi_n^T \end{bmatrix} [\Phi_0, \Phi_1, \dots, \Phi_n] = \begin{bmatrix} \Phi_0^T \Phi_0 & \dots & \Phi_0^T \Phi_n \\ \dots & \dots & \dots \\ \Phi_n^T \Phi_0 & \dots & \Phi_n^T \Phi_n \end{bmatrix} \\
 &= \begin{bmatrix} (\Phi_0, \Phi_0) & \dots & (\Phi_0, \Phi_n) \\ \dots & \dots & \dots \\ (\Phi_n, \Phi_0) & \dots & (\Phi_n, \Phi_n) \end{bmatrix} = G
 \end{aligned}$$

注:

(1) 由于 A 是列满秩矩阵, 所以 $A^T A$ 是 $(n+1) \times (n+1)$ 的对称正定阵, 可用Cholesky分解法求解法方程

$$A^T A C = A^T Y$$

证: $\forall x \neq 0, x^T A^T A x = (Ax, Ax) > 0$

\therefore 法方程 $GC = F$ (或 $A^T A C = A^T Y$) 存在唯一解.

法方程 $GC = F$ ($A^T A C = A^T Y$) 的解

\Leftrightarrow 矛盾方程组 $AC = Y$ 的最小二乘解。

称 A 为回归矩阵, 在 $Matlab$ 中可用左除法求解

$$C = A \setminus Y$$

(2) 且有 $\text{cond}_2(A^T A) = (\text{cond}_2(A))^2$

因此，法方程常常表现出是病态方程组。

(3) 取基函数为 $\varphi_0(x) = 1, \varphi_1(x) = x, \dots, \varphi_n(x) = x^n$,

则
$$A = \begin{bmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 1 & x_m & x_m^2 & \cdots & x_m^n \end{bmatrix}$$

实际计算中要计算 $x_0^n, x_1^n, \dots, x_m^n, \sum_{i=1}^m x_i^k, (k = 0, 1, \dots, 2n)$

当数据点数值很大时，可能会在计算中溢出。

三、法方程的求解

求解法方程 $A^T A C = A^T Y$ 或 $GC = F$ (取 $W = I$)

1. 确定 $n+1$ 个线性无关函数 $\{\varphi_j(x)\}_{j=0}^n$ 的具体形式

常用的代数多项式拟合是取

$$\varphi_j(x) = x^j \quad (j = 0, 1, \dots, n)$$

最佳平方逼近函数的形式是

$$s(x) = c_0 + c_1 x + c_2 x^2 + \dots + c_n x^n$$

由法方程求出 $c_j \quad (j = 0, 1, \dots, n)$

$s(x)$ 又称为最小二乘拟合函数

2. 构造法方程

用基函数 $1, x, x^2, \dots, x^n$

回归矩阵 $A = \begin{bmatrix} 1 & x_0 & x_0^2 & \cdots & x_0^n \\ 1 & x_1 & x_1^2 & \cdots & x_1^n \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 1 & x_m & x_m^2 & \cdots & x_m^n \end{bmatrix}$

$$Y = (y_0, y_1, \dots, y_m)^T$$

得到法方程 $A^T A C = A^T Y$

3. 法方程的求解

$A^T A$ 是对称正定阵，用Cholesky分解： $A^T A = LL^T$ 。

$$\begin{cases} LZ = A^T Y & \text{求 } Z \\ L^T C = Z & \text{求 } C \end{cases}$$

例 给出数据点

i	0	1	2	3	4
x_i	0.0	0.25	0.5	0.75	1.0
y_i	1.0	1.2840	1.6487	2.1170	2.7183
w_i	1.0	1.0	1.0	1.0	1.0

试用 $1, x, x^2$ 构造二次最佳平方逼近多项式。

解： 设 $s(x) = c_0 + c_1x + c_2x^2$

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad \varphi_2(x) = x^2$$

$$\Phi_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad \Phi_1 = \begin{bmatrix} 0.0 \\ 0.25 \\ 0.5 \\ 0.75 \\ 1.0 \end{bmatrix}, \quad \Phi_2 = \begin{bmatrix} 0.0^2 \\ 0.25^2 \\ 0.5^2 \\ 0.75^2 \\ 1.0^2 \end{bmatrix}, \quad Y = \begin{bmatrix} 1.0 \\ 1.2840 \\ 1.6487 \\ 2.1170 \\ 2.7183 \end{bmatrix}$$

$$G = \begin{bmatrix} (\Phi_0, \Phi_0) & (\Phi_0, \Phi_1) & (\Phi_0, \Phi_2) \\ (\Phi_1, \Phi_0) & (\Phi_1, \Phi_1) & (\Phi_1, \Phi_2) \\ (\Phi_2, \Phi_0) & (\Phi_2, \Phi_1) & (\Phi_2, \Phi_2) \end{bmatrix} = \begin{bmatrix} 5 & 2.5 & 1.875 \\ 2.5 & 1.875 & 1.5625 \\ 1.875 & 1.5625 & 1.3825 \end{bmatrix}$$

$$\begin{aligned} F &= ((Y, \Phi_0), (Y, \Phi_1), (Y, \Phi_2))^T \\ &= (8.7680, 5.4514, 4.4015)^T \end{aligned}$$

解法方程 $GC = F$

解出 $c_0 = 1.0052, \quad c_1 = 0.8641, \quad c_2 = 0.8437$

于是得到二次最佳平方逼近多项式

$$s(x) = 1.0052 + 0.8641x + 0.8437x^2$$

四、由正交函数组构造最佳平方逼近多项式

- ① 原理：若函数组 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x)$ 是关于点集 $\{x_0, x_1, \dots, x_m\}$ 和带权 w_0, w_1, \dots, w_m 的正交函数组，

$$\text{即 } (\varphi_k(x), \varphi_j(x)) = (\Phi_k, \Phi_j) = \begin{cases} = 0 & j \neq k \\ \neq 0 & j = k \end{cases}$$

则法方程 $GC = F$

其中 $G = \begin{bmatrix} (\Phi_0, \Phi_0) & & \\ & (\Phi_1, \Phi_1) & \\ & & (\Phi_n, \Phi_n) \end{bmatrix}$

$$F = ((Y, \Phi_0) \quad (Y, \Phi_1) \quad \dots \quad (Y, \Phi_n))^T$$

则法方程 $GC = F$

其中 $G = \begin{bmatrix} (\Phi_0, \Phi_0) & & \\ & (\Phi_1, \Phi_1) & \\ & & \ddots \\ & & & (\Phi_n, \Phi_n) \end{bmatrix}$

$$F = ((Y, \Phi_0) \quad (Y, \Phi_1) \quad \cdots \quad (Y, \Phi_n))^T$$

$$c_j = \frac{(Y, \Phi_j)}{(\Phi_j, \Phi_j)} = \frac{\sum_{i=0}^m w_i f(x_i) \varphi_j(x_i)}{\sum_{i=0}^m w_i \varphi_j^2(x_i)} \quad (j = 0, 1, 2, \dots, n)$$

最佳平方逼近多项式为 $s(x) = \sum_{j=0}^n c_j \varphi_j(x)$

2.构造关于点集的正交函数组 (Chap2)

由 $1, x, x^2, \dots, x^n$ 构造关于点集 $\{x_i\}_{i=0}^m$ 的首1正交多项式

$$\begin{cases} \varphi_0(x) = 1 \\ \varphi_{k+1}(x) = (x - a_{k+1})\varphi_k(x) - \beta_k \varphi_{k-1}(x) \quad (k = 0, 1, 2, \dots) \end{cases}$$

其中

$$\begin{cases} \alpha_k = \frac{(x\varphi_k(x), \varphi_k(x))}{(\varphi_k(x), \varphi_k(x))} \quad (k = 0, 1, 2, \dots) \\ \beta_0 = 0, \beta_k = \frac{(\varphi_k(x), \varphi_k(x))}{(\varphi_{k-1}(x), \varphi_{k-1}(x))} \quad (k = 1, 2, \dots) \end{cases}$$

式中内积定义为

$$(\varphi_k(x), \varphi_j(x)) = (\Phi_k, \Phi_j) = \sum_{i=0}^m w_i \varphi_k(x_i) \varphi_j(x_i)$$

$$(x\varphi_k(x), \varphi_k(x)) = \sum_{i=0}^m w_i x_i \varphi_k^2(x_i)$$

例 给出数据点

i	$= 0$	1	2	3	4
x_i	$= 0.0$	0.25	0.5	0.75	1.0
y_i	$= 1.0$	1.2840	1.6487	2.1170	2.7183
w_i	$= 1.0$	1.0	1.0	1.0	1.0

用关于点集的正交函数组构造二次最佳平方逼近多项式。

解: (1) 先构造关于点集 $\{0, 0.25, 0.5, 0.75, 1.0\}$ 和权 $w_i = 1$, 的正交函数组 $\{\varphi_0(x), \varphi_1(x), \varphi_2(x)\}$.

$$\varphi_0(x) = 1, \quad \varphi_1(x) = (x - \alpha_1)\varphi_0(x)$$

$$\alpha_1 = \frac{(x\varphi_0(x), \varphi_0(x))}{(\varphi_0(x), \varphi_0(x))}$$

$$\Phi_0 = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix}, \Phi_{00} = \begin{pmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0.25 \\ 0.5 \\ 0.75 \\ 1 \end{pmatrix}$$

$$\alpha_1 = \frac{(x\varphi_0(x), \varphi_0(x))}{(\varphi_0(x), \varphi_0(x))} = \frac{(\Phi_{00}, \Phi_0)}{(\Phi_0, \Phi_0)} = \frac{2.5}{5} = \frac{1}{2}$$

$$\varphi_1(x) = x - \frac{1}{2}$$

$$\varphi_2(x) = (x - \alpha_2)\varphi_1(x) - \beta_1\varphi_0(x)$$

$$\alpha_2 = \frac{(x\varphi_1(x), \varphi_1(x))}{(\varphi_1(x), \varphi_1(x))}, \beta_1 = \frac{(\varphi_1(x), \varphi_1(x))}{(\varphi_0(x), \varphi_0(x))}$$

$$\Phi_1 = (-0.5, -0.25, 0, 0.25, 0.5)^T$$

$$\Phi_{11} = (0, -0.0625, 0, 0.1875, 0.5)^T$$

$$\alpha_2 = \frac{1}{2}, \quad \beta_1 = \frac{1}{8}$$

$$\varphi_2(x) = \left(x - \frac{1}{2}\right)^2 - \frac{1}{8}$$

$$\varphi_0(x) = 1, \varphi_1(x) = x - \frac{1}{2}, \varphi_2(x) = (x - \frac{1}{2})^2 - \frac{1}{8}$$

$$Y = (1.0, 1.2840, 1.6487, 2.1170, 2.7183)^T$$

$$\Phi_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad \Phi_1 = \begin{bmatrix} -0.5 \\ -0.25 \\ 0.0 \\ 0.25 \\ 0.5 \end{bmatrix}, \quad \Phi_2 = \begin{bmatrix} 0.125 \\ -0.0625 \\ -0.125 \\ -0.0625 \\ 0.125 \end{bmatrix}, \quad Y = \begin{bmatrix} 1.0 \\ 1.2840 \\ 1.6487 \\ 2.1170 \\ 2.7183 \end{bmatrix}$$

$$c_0 = (Y, \Phi_0) / (\Phi_0, \Phi_0) = \sum_{i=0}^4 y_i \times 1 / \sum_{i=0}^4 1 = 8.768 / 5 = 1.7536$$

$$c_1 = (Y, \Phi_1) / (\Phi_1, \Phi_1) = \sum_{i=0}^4 y_i \times (x_i - \frac{1}{2}) / \sum_{i=0}^4 (x_i - \frac{1}{2})^2 = 1.7078$$

$$c_2 = (Y, \Phi_2) / (\Phi_2, \Phi_2) = \sum_{i=0}^4 y_i \times ((x_i - \frac{1}{2})^2 - \frac{1}{8}) / \sum_{i=0}^4 ((x_i - \frac{1}{2})^2 - \frac{1}{8})^2 \\ = 0.8437$$

得到二次最佳平方逼近多项式为

$$s(x) = 1.7536 + 1.7078(x - \frac{1}{2}) + 0.8437((x - \frac{1}{2})^2 - \frac{1}{8})$$

最佳平方逼近存在唯一。

3. 误差估计

由最佳平方逼近的误差估计式

$$\begin{aligned}\|\delta\|^2 &= \|f - s\|^2 = (f - s, f - s) = (f, f) - (s, f) \\ &= (f, f) - \left(\sum_{j=0}^n c_j \varphi_j, f\right) = (f, f) - \sum_{j=0}^n c_j (\varphi_j, f)\end{aligned}$$

对离散数据的最佳平方逼近误差

$$\|\delta\|^2 = (Y, Y) - \left(\sum_{j=0}^n c_j \Phi_j, Y\right) = \|Y\|^2 - \sum_{j=0}^n c_j (\Phi_j, Y)$$

其中 $Y = (f(x_0), f(x_1), \dots, f(x_m))^T$

如果用正交函数组构造最佳平方逼近元, 则

$$c_j = (Y, \Phi_j) / (\Phi_j, \Phi_j), \quad (Y, \Phi_j) = c_j \|\Phi_j\|^2$$

$$\text{因此有 } \|\delta\|^2 = \|Y\|^2 - \sum_{j=0}^n c_j^2 \|\Phi_j\|^2$$

误差递推关系

第一步，用 $\varphi_0(x), \varphi_1(x), \dots, \varphi_{n-1}(x)$ 作逼近，误差

$$\|\delta_{n-1}\|^2 = \|Y\|^2 - \sum_{j=0}^{n-1} c_j^2 \|\Phi_j\|^2$$

第二步，用 $\varphi_0(x), \varphi_1(x), \dots, \varphi_{n-1}(x)$, $\varphi_n(x)$ 作逼近，误差

$$\begin{aligned} \|\delta_n\|^2 &= \|Y\|^2 - \sum_{j=0}^n c_j^2 \|\Phi_j\|^2 \\ &= \|Y\|^2 - \sum_{j=0}^{n-1} c_j^2 \|\Phi_j\|^2 - c_n^2 \|\Phi_n\|^2 \end{aligned}$$

即有 $\|\delta_n\|^2 = \|\delta_{n-1}\|^2 - c_n^2 \|\Phi_n\|^2 < \|\delta_{n-1}\|^2$

最佳平方逼近的误差，随着选择的拟合基函数个数增加而减少

第四节 非线性最小二乘曲线拟合

例1: 已知数据表 $x_i = x_0, x_1, \dots, x_m,$

$$y_i = y_0, y_1, \dots, y_m,$$

用公式 $s(x) = a + bx^3$ 拟合所给数据。

解: $\varphi_0(x) = 1, \varphi_1(x) = x^3, s(x) = a\varphi_0(x) + b\varphi_1(x)$

$$A = \begin{bmatrix} 1 & x_0^3 \\ 1 & x_1^3 \\ \vdots & \vdots \\ 1 & x_m^3 \end{bmatrix}, \quad Y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_m \end{bmatrix}, \quad A^T A \begin{bmatrix} a \\ b \end{bmatrix} = A^T Y$$

例2: 已知数据表 $x_i = x_0, x_1, \dots, x_m,$

$$y_i = y_0, y_1, \dots, y_m,$$

用公式 $s(x) = \frac{1}{a + bx^3}$ 拟合所给数据。

解: 令
$$f(x) = \frac{1}{s(x)} = a + bx^3$$

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x^3, \quad f(x) = a\varphi_0(x) + b\varphi_1(x)$$

$$A = \begin{bmatrix} 1 & x_0^3 \\ 1 & x_1^3 \\ \vdots & \vdots \\ 1 & x_m^3 \end{bmatrix}, \quad F = \begin{bmatrix} 1/y_0 \\ 1/y_1 \\ \vdots \\ 1/y_m \end{bmatrix}, \quad A^T A \begin{bmatrix} a \\ b \end{bmatrix} = A^T F$$

例3: 已知数据表 $x_i = x_0, x_1, \dots, x_m$,

$$y_i = y_0, y_1, \dots, y_m,$$

用公式 $s(x) = ae^{bx}$ 拟合所给数据。

解: 令 $f(x) = \ln s(x) = \ln a + bx$

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad f(x) = \ln a \varphi_0(x) + b \varphi_1(x)$$

$$A = \begin{bmatrix} 1 & x_0 \\ 1 & x_1 \\ \vdots & \vdots \\ 1 & x_m \end{bmatrix}, \quad F = \begin{bmatrix} \ln y_0 \\ \ln y_1 \\ \vdots \\ \ln y_m \end{bmatrix}, \quad A^T A \begin{bmatrix} \ln a \\ b \end{bmatrix} = A^T F$$

例4: 已知数据表 $x_i = x_0, x_1, \dots, x_m,$

$$y_i = y_0, y_1, \dots, y_m,$$

用公式 $s(x) = a + \frac{b}{x}$ 拟合所给数据。

解: $\varphi_0(x) = 1, \varphi_1(x) = \frac{1}{x}, s(x) = a\varphi_0(x) + b\varphi_1(x)$

$$A = \begin{bmatrix} 1 & 1/x_0 \\ 1 & 1/x_1 \\ \vdots & \vdots \\ 1 & 1/x_m \end{bmatrix}, \quad Y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_m \end{bmatrix}, \quad A^T A \begin{bmatrix} a \\ b \end{bmatrix} = A^T Y$$